

Objetivo

El objetivo de este trabajo práctico es realizar un análisis completo del ciclo de vida de un problema de Machine Learning, centrándose en la preparación de los datos, la prevención de Data Leakage, la estrategia de validación y la correcta elección de métricas orientadas al negocio.

El trabajo consiste en generar un Jupyter Notebook (.ipynb) que incluya todo el código, análisis y explicaciones hechas por ustedes. **El pensamiento crítico es fundamental:** las celdas de texto (Markdown) donde justifiquen sus decisiones tendrán tanto o más peso que la correcta ejecución del código.

Parte I: El Camino de los Datos (Telco Churn)

Trabajarán con el dataset **Telco Customer Churn**, utilizando modelos predictivos básicos.

1. Introducción al problema y Análisis Exploratorio

- Presenten una descripción concisa del conjunto de datos y el problema de negocio a resolver.
- Realicen un análisis exploratorio que incluya estadísticas descriptivas y al menos tres visualizaciones relevantes.
- Al cargar los datos, es posible que algunas columnas no sean reconocidas directamente como numéricas. Identifiquen por qué sucede esto, corrijan el problema y expliquen qué impacto tendría en un modelo si este tipo de anomalías no se detectan a tiempo.

2. Preprocesamiento y prevención de Data Leakage

- **Valores faltantes:** Apliquen una estrategia justificada para manejar los valores nulos.
- **Variables categóricas y Feature Scaling:** Transformen las variables de texto y apliquen escalado a las variables numéricas en los casos que crean necesarios.
- El orden de las operaciones es importante. Expliquen explícitamente en una celda de texto en qué momento del código se debe realizar la división de los datos en entrenamiento y testeo (*Train/Test Split*) en relación con el escalado y la imputación. Si lo hicieran en el orden incorrecto, ¿qué problema conceptual estarían introduciendo?

3. Estrategia de Validación

- Implementen una validación cruzada utilizando **K-Fold Cross-Validation** (con $K=5$) sobre el conjunto de entrenamiento para su modelo.
- ¿Por qué utilizar K-Fold Cross-Validation en lugar de una simple partición de *Holdout*? Discutan qué ventajas les da esta técnica considerando la distribución de la variable objetivo en este dataset. ¿Sería conveniente usar un *Stratified K-Fold*? Justifiquen.

4. Evaluación del modelo base

- Entrenen el modelo final sobre todo el conjunto de entrenamiento y evalúenlo sobre el conjunto de testeo. Calculen: Matriz de Confusión, Accuracy, Precision, Recall y F1-Score.
- Observen el Accuracy obtenido. Sabiendo el porcentaje de clientes que no abandona el servicio, ¿es el Accuracy una buena métrica para este problema? Si crearan un modelo *naïve* que siempre prediga la clase mayoritaria, ¿qué Accuracy tendría?

5. Análisis de Negocio e Impacto de las Métricas

Supongan que el equipo de Marketing va a utilizar las predicciones de su modelo para ofrecer **un descuento del 50 % por 3 meses** a los clientes que estén a punto de fugarse.

- Creen un segundo modelo aplicando alguna técnica para lidiar con el desbalanceo de clases (ej. *Oversampling*, *Undersampling*). Vuelvan a calcular las métricas.
- En el caso de negocio planteado:
 1. ¿Qué impacto económico tiene para la empresa un Falso Positivo?
 2. ¿Qué impacto tiene un Falso Negativo?
 3. Si el descuento ofrecido es muy costoso para la empresa, ¿qué métrica (Precision o Recall) intentarían maximizar y por qué? ¿Y si el descuento fuera casi gratuito? Justifiquen basándose en sus matrices de confusión.

Parte II: Reformulando el Problema

En el mundo real, un mismo conjunto de datos puede utilizarse para responder a múltiples preguntas. En esta sección, deberán abandonar la predicción de **Churn** e inventar un problema predictivo completamente nuevo utilizando el mismo dataset.

- Elijan una variable distinta a **Churn** para que sea su nuevo target. Si es numérica o multi-clase, adaptenla a un problema de clasificación binaria justificando el corte.
- Entrenen un modelo simple (*out-of-the-box*) para predecir este nuevo target y calculen sus métricas de testeo. ¿Es predecible el nuevo objetivo?

Conclusiones

- Resuman los hallazgos principales del análisis y la efectividad de sus modelos para los problemas planteados.
- Sugieran posibles mejoras para iteraciones futuras.

Modalidad de Entrega

- El trabajo se debe realizar en grupos de 3 personas. Únicamente **1 integrante** del grupo debe realizar la entrega utilizando la carpeta correspondiente en el Campus Virtual.
- Las consultas virtuales deben realizarse **exclusivamente** a través del foro **TP1 — Consultas** en el Campus Virtual.
- El trabajo se debe entregar hasta las **23:59hs del miércoles 2 de septiembre**.